

Praca Dyplomowa Magisterska

Mikita Hudalin
225793

Wykrywanie fałszywych opinii za pomocą metod uczenia maszynowego

Fake Reviews Detection with Machine Learning Methods

Praca dyplomowa na kierunku:
Informatyka i Ekonometria

Praca wykonana pod kierunkiem
dra Tomasza Ząbkowskiego
Instytut Informatyki Technicznej
Katedra Sztucznej Inteligencji

Warszawa, 2025



SZKOŁA GŁÓWNA
GOSPODARSTWA
WIEJSKIEGO

Wydział Zastosowań
Informatyki
i Matematyki

Oświadczenie promotora pracy

Oświadczam, że niniejsza praca została przygotowana pod moim kierunkiem i stwierdzam, że spełnia warunki do przedstawienia tej pracy w postępowaniu o nadanie tytułu zawodowego.

Data..... Podpis promotora

Oświadczenie autora pracy

Świadom odpowiedzialności prawnej, w tym odpowiedzialności karnej za złożenie fałszywego oświadczenia, oświadczam, że niniejsza praca dyplomowa została napisana przeze mnie samodzielnie i nie zawiera treści uzyskanych w sposób niezgodny z obowiązującymi przepisami prawa, w szczególności ustawą z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (Dz.U. 2019 poz. 1231 z późn. zm.).

Oświadczam, że przedstawiona praca nie była wcześniej podstawą żadnej procedury związanej z nadaniem dyplomu lub uzyskaniem tytułu zawodowego.

Oświadczam, że niniejsza wersja pracy jest identyczna z załączoną wersją elektroniczną. Przyjmuję do wiadomości, że praca dyplomowa poddana zostanie procedurze antyplagiatowej.

Data..... Podpis autora pracy

Streszczenie

Wykrywanie fałszywych opinii za pomocą metod uczenia maszynowego

W niniejszej pracy przedstawiono problem fałszywych opinii publikowanych w Internecie oraz możliwości ich wykrywania z wykorzystaniem metod uczenia maszynowego. Omówiono różne typy fałszywych recenzji, źródła ich powstawania oraz ich wpływ na decyzje konsumentów. Przeprowadzono eksperymenty z wykorzystaniem różnych klasyfikatorów takich jak regresja logistyczna, Las Losowy, LSTM oraz BERT. Na podstawie wyników porównano skuteczność poszczególnych metod. Praca może mieć zastosowanie w moderacji treści online.

Słowa kluczowe – fałszywe opinie, uczenie maszynowe, analiza tekstu, NLP, klasyfikacja binarna, detekcja oszustw

Summary

Fake Reviews Detection with Machine Learning Methods

This thesis presents the problem of fake reviews published on the Internet and the possibilities of detecting them using machine learning methods. Different types of fake reviews, their sources and their impact on consumer decisions are discussed. Experiments were conducted using different classifiers such as logistic regression, Random Forest, LSTM and BERT. Based on the results, the effectiveness of the different methods was compared. The findings can be applied to online content moderation.

Keywords – fake reviews, machine learning, text analysis, NLP, binominal classification, fraud detection

Spis treści

1. Wstęp.....	9
1.1. Tło i motywacja pracy.....	9
1.2. Cel i pytania badawcze	11
1.3. Struktura pracy	11
2. Przegląd literatury	13
2.1. Definicja fałszywej opinii	13
2.2. Etyczny aspekt fałszywych opinii oraz możliwość ich wykrywania za pomocą algorytmów uczenia maszynowego	14
3. Dane i ich przygotowanie.....	16
3.1. Dane	16
3.2. Wstępne przetwarzanie danych.....	18
3.2.1. Czyszczenie danych	18
3.2.2. Tokenizacja	18
3.2.3. Przekształcenie tekstów do formatu numerycznego	19
4. Wybrane metody wykrywania fałszywych opinii	21
4.1. Metody klasyczne	21
4.1.1. Regresja logistyczna	21
4.1.2. Las Losowy	23
4.2. Sieci neuronowe	24
4.2.1. LSTM.....	24
4.3. Transformery.....	25
4.3.1. BERT	25
4.4. Metody oceny modeli.....	26
4.4.1. Macierz pomyłek	26
4.4.2. Metryki jakości klasyfikacji.....	27
4.4.1. Krzywa ROC oraz miara AUC	28
5. Implementacja i eksperymenty	29
5.1. Regresja logistyczna	29
5.1.1. Dobór hiperparametrów	29
5.1.2. Analiza macierzy pomyłek	30
5.1.1. Analiza krzywej ROC	32
5.2. Las Losowy	33
5.2.1. Dobór hiperparametrów	33


5.2.2. Analiza macierzy pomyłek	34
5.2.3. Analiza krzywej ROC	36
5.3. LSTM	37
5.3.1. Dobór hiperparametrów	37
5.3.2. Uczenie najlepszego modelu	39
5.3.3. Analiza macierzy pomyłek	41
5.3.4. Analiza krzywej ROC	42
5.4. BERT	43
5.4.1. Dobór hiperparametrów	43
5.4.2. Uczenie najlepszego modelu	44
5.5. Analiza macierzy pomyłek	46
5.6. Analiza krzywej ROC.....	47
5.7. Dyskusja wyników	48
5.8. Potencjalne kierunki dalszych badań.....	50
6. Wnioski.....	51
7. Spis literatury.....	52
8. Spis rysunków	56
9. Spis tabel.....	57

1. Wstęp

1.1. Tło i motywacja pracy

W dobie dynamicznego rozwoju ECommerce (handel internetowy) recenzje online oraz oceny produktów stały się jednym z kluczowych elementów wpływających na decyzje osób kupujących towary lub usługi online (Karakaya, F, 2010). Te dwa czynniki dostarczają informacje, które pomagają konsumentom ocenić jakość i dopasowanie produktów do ich potrzeb w warunkach ograniczonej możliwości fizycznej interakcji z towarem. Czytając opinie innych osób w Internecie, konsumenci mogą zapoznać się z doświadczeniem innych osób, porównać zalety i wady produktu, a także ocenić ważność tych aspektów dla siebie. W naturalny sposób pozytywne recenzje często zwiększają zaufanie konsumentów i wzmacniają intencje zakupowe (Liu, Mengwei i Zhou, Ming, 2012). Produkty o wysokiej ocenie kupujących częściej kojarzą się z wysokim poziomem jakości i stabilną satysfakcją innych użytkowników. W przeciwieństwie do pozytywnych opinii, negatywne recenzje mają tendencję do wywoływania wątpliwości i kształtowania postrzegania ryzyka. Takie produkty zazwyczaj są często unikane, ponieważ postrzega się je jako niegodne zaufania (Cheng, Y. H., 2015).

Na ważność opinii w Internecie jednoznacznie wskazują badania jednego z najbardziej rozwiniętych rynków handlu internetowego – Stanów Zjednoczonych, gdzie handel internetowy reprezentuje około 14% całej sprzedaży (Akesson, J. i in., 2023). Jedno z takich badań pokazuje, że 96% osób regularnie lub okazjonalnie czyta recenzje online (Rys. 1), a 84% ufa im tak samo, jak osobistym rekomendacjom. Jednocześnie, jeżeli chodzi o szybkość podejmowania swoich własnych decyzji na bazie zapoznanych opinii – robią to bardzo szybko: 68% osób wyrabia sobie opinię po przeczytaniu od jednej do sześciu recenzji online (BrightLocal, 2023).



Rysunek 1. Jak często użytkownicy czytają opinie w Internecie? (zawsze, regularnie, czasem, nigdy).

Źródło: BrightLocal Survey, 2023

Z innej strony, opinie te są również jednym z najbardziej istotnych źródeł informacji o swoich produktach lub usługach dla sprzedawców, którzy starają się zoptymalizować swoje oferty na podstawie tych informacji zwrotnych, poprawić ewentualne problemy związane z jakością towarów lub usług oraz budować zaufanie do swoich marek (Ostrowska, I. , 2010).

Jednocześnie, wraz ze wzrostem znaczenia opinii produktowych w procesie zakupowym, pojawiło się zjawisko fałszywych recenzji (ang. fake reviews). Fałszywe opinie są generowane głównie na potrzeby manipulacji osobami kupującymi. Mogą być generowane zarówno przez samych sprzedawców w celu sztucznego podniesienia atrakcyjności swoich produktów, jak i przez konkurencję, aby zdyskredytować rywali. Wpływa to negatywnie na przejrzystość rynku, prowadzi do dezinformacji konsumentów oraz osłabia wiarygodność platform e-commerce.

Rozpoznawanie i eliminacja fałszywych opinii stanowią wyzwanie dla całej branży handlu elektronicznego. Sprawdzenie 720 mln opinii konsumenckich na jednej z najpopularniejszych platform handlu internetowego Amazon wykryło, że około 42% z tych opinii okazały się fałszywymi albo niegodnymi zaufania (Akesson, J. i in., 2023).

W związku z tym, coraz większe zastosowanie mają metody oparte na uczeniu maszynowym (ang. machine learning) oraz sztucznej inteligencji, które pozwalają na automatyczną analizę dużych zbiorów danych oraz skuteczniejsze identyfikowanie podejrzanych opinii.

1.2.Cel i pytania badawcze

Głównym celem niniejszej pracy jest opracowanie skutecznego modelu uczenia maszynowego, który pozwoli na wykrywanie fałszywych opinii w ECommerce. W ramach tego celu zostanie przeprowadzona analiza dotychczasowych metod wykrywania fałszywych treści tekstowych, identyfikacja kluczowych cech opinii oraz wybór najbardziej odpowiednich algorytmów do klasyfikacji opinii jako prawdziwych lub fałszywych.

Aby osiągnąć ten cel, postawiono następujące pytania badawcze:

- Czy nowoczesne algorytmy uczenia maszynowego nadają się do skutecznego wykrywania fałszywych opinii wygenerowanych przez sztuczną inteligencję?
- Które algorytmy uczenia maszynowego są najskuteczniejsze w przypadku analizy treści opinii konsumentów?

Zastosowanie skutecznego modelu wykrywania fałszywych recenzji może mieć istotne przełożenie biznesowe. Przede wszystkim, przyczyni się do zwiększenia zaufania konsumentów do opinii zamieszczanych w serwisach ECommerce, co może wpłynąć na większą świadomość podejmowanych decyzji zakupowych. Ponadto, skuteczna detekcja fałszywych recenzji pozwoli sprzedawcom na ochronę ich reputacji oraz ograniczenie strat finansowych wynikających z nieuczciwej konkurencji. Wdrożenie takiego systemu może także prowadzić do optymalizacji algorytmów rekomendacyjnych, co pozytywnie wpłynie na funkcjonowanie całego ekosystemu sprzedaży w Internecie.

1.3.Struktura pracy

Praca została podzielona na sześć rozdziałów. Pierwszym z nich pełni rolę wprowadzenia do analizowanego zagadnienia. Opisany został problem badawczy i cel pracy, przedstawiono główne pytania badawcze. Znajduje się tutaj również krótki opis struktury pracy.

Drugi rozdział służy jako teoretyczne wprowadzenie do tematyki fałszywej opinii. Zawarte w nim treści opisują pojęcie fałszywej opinii oraz omawiają etyczny kontekst ich wykrywania.

W rozdziale trzecim opisany został wykorzystany zbiór danych oraz proces jego przygotowania do dalszej analizy. W szczególności zostały opisane proces czyszczenia, tokenizacji oraz przekształcenia tekstów do formatu numerycznego.

Rozdział czwarty poświęcony jest opisowi metod analizy tekstów z wykorzystaniem uczenia maszynowego. Omówiono zarówno klasyczne algorytmy, takie jak regresja logistyczna czy lasy losowe, jak i bardziej zaawansowane algorytmy, w tym sieci neuronowe LSTM oraz modele oparte na architekturze transformerów.

Rozdział piąty obejmuje część eksperymentalną. W szczególności opisane zostały proces implementacji wybranych modeli, wyniki ich działania oraz analiza skuteczności poszczególnych modeli. Omówiono także proces doboru hiperparametrów. Rozdział kończy dyskusja wyników oraz propozycje kierunków dalszych badań.

Ostatni, szósty rozdział zawiera podsumowanie całej pracy. Zawarto w nim najważniejsze wnioski oraz odpowiedzi na pytania badawcze.

2. Przegląd literatury

2.1. Definicja fałszywej opinii

Fałszywa opinia to recenzja, komentarz lub ocena, która wprowadza w błąd odbiorcę poprzez podanie nieprawdziwych, zmanipulowanych lub sztucznie wygenerowanych informacji (Jindal, N., i Liu, B., 2008). Charakteryzuje się również tym, że jest napisana lub wygenerowana bez rzeczywistego doświadczenia z recenzowanym produktem lub usługą (Salminen, J i in., 2022). Takie opinie mogą być publikowane w celu wpływania na decyzje zakupowe konsumentów, reputację sprzedawców lub ranking produktów i usług na platformach ECommerce.

Główne typy fałszywych opinii:

- Pozytywne opinie o niskiej wartości merytorycznej

Opinie te są często generowane przez boty, niskiej jakości usługi recenzenckie lub osoby wynagradzane za ich publikowanie. Charakteryzują się ogólnikowymi stwierdzeniami, brakiem szczegółowych informacji na temat produktu oraz nadmiernie entuzjastycznym tonem (Ott, M. i in., 2011).

- Negatywne opinie manipulujące

Celem tych opinii jest zdyskredytowanie produktu lub usługi poprzez sztucznie obniżenie oceny. Czasami są one publikowane przez konkurencję w celu osłabienia pozycji rynkowej danego sprzedawcy. Mogą zawierać przesadzone zarzuty, nieprawdziwe informacje lub powtarzalne schematy oskarżeń (Mukherjee, A. i in., 2012).

- Opinie sponsorowane (wykupione)

To recenzje pisane na zlecenie producenta lub sprzedawcy, które nie są oznaczone jako materiał promocyjny. Opinie sponsorowane mogą być pisane przez prawdziwych użytkowników, ale ich treść jest ukierunkowana na promowanie produktu, co wpływa na ich wiarygodność (Mayzlin, D i in., 2014).

- Opinie generowane przez modele językowe

Rozwój technologii NLP (ang. Natural Language Processing) i dużych modeli

językowych (np. GPT) umożliwił tworzenie zaawansowanych fałszywych opinii. Opinie te mogą być niemal nieodróżnialne od tych pisanych przez ludzi, co czyni ich wykrywanie szczególnie trudnym. Modele językowe mogą generować recenzje w różnych stylach i tonach, co sprawia, że mogą skutecznie wprowadzać konsumentów w błąd (Ahmed, H i in., 2018).

Fałszywe opinie, niezależnie od ich rodzaju, mają istotny wpływ na funkcjonowanie rynków ECommerce i percepcję produktów przez użytkowników.

W niniejszej pracy szczególna uwaga zostanie przedzielona problematyce wykrywania fałszywych opinii wygenerowanych przez modele językowe.

2.2. Etyczny aspekt fałszywych opinii oraz możliwość ich wykrywania za pomocą algorytmów uczenia maszynowego

Oczywisty jest ten fakt, że fałszywe opinie na stronach sklepów internetowych stanowią istotne wyzwanie zarówno dla konsumentów, jak i przedsiębiorstw, wpływając na decyzje zakupowe oraz reputacje marek (Mahavidyalaya, L. M. V., & Izhar, F, 2024). Modele uczenia maszynowego otwierają nowe możliwości w przeciwdziałaniu takim manipulacjom, ale jednocześnie zastosowanie takich modeli wiąże się z szeregiem dylematów etycznych (Siau, K., i Wang, W., 2020).

Głównym problemem etycznym korelującym z problemem fałszywych opinii jest problem dezinformacji. Dezinformację określamy jako „fałszywe, zmanipulowane lub wyrwane z kontekstu informacje, rozpowszechnione w sposób świadomy, z zamiarem oszukania lub wprowadzenia w błąd odbiorców” (Zielińska, I., 2024).

W przypadku fałszywych recenzji w Internecie dezinformacja wprowadza konsumentów w błąd oraz podważa ich zdolność do podejmowania świadomych decyzji. Firmy mogą wykorzystywać je jako narzędzie nieuczciwej konkurencji, co wpływa na rynkową równowagę i szkodzi tym podmiotom gospodarczym, które prowadzą swoją działalność w sposób uczciwy. Jednocześnie w perspektywie długofalowej osłabiają zaufanie konsumentów do platform świadczących usługi pośredników w sprzedaży towarów lub usług oraz ich systemów ocen i rekomendacji (Budzanowska-Drzewiecka, M., 2023).

Wykorzystanie algorytmów uczenia maszynowego (ang. Machine Learning - ML) oprócz nowych możliwości w wykrywaniu fałszywych treści recenzji oraz

rozwiązań skali niesie ze sobą potencjalne zagrożenia związane z prywatnością użytkowników oraz transparentnością działania systemów (Szozkiewicz, Ł., 2021).

Kluczowe problemy obejmują:

- Prywatność danych – W naturalny sposób algorytmy automatycznej analizy treści tekstowych recenzji użytkowników wymagają dostępu do danych osobowych tych użytkowników oraz do treści tekstowych recenzji. Może to budzić obawy dotyczące ochrony tych danych oraz nie być zgodne z polityką niektórych platform internetowych (Tom, E. I in., 2020).
- Ryzyko błędnej klasyfikacji oraz etyczny aspekt karania fałszywych opinii – Modele ML mogą błędnie klasyfikować prawdziwe opinie jako fałszywe, co może skutkować niesłusznymi konsekwencjami dla użytkowników i firm. Decyzja o usuwaniu treści albo blokowaniu użytkowników powinna polegać na jasnych i przejrzystych zasadach (Zarsky, T., 2016), (Verma, S., 2019).
- Przejrzystość algorytmów – modele ML wykorzystane na potrzeby klasyfikacji recenzji nie muszą działać na zasadzie „czarnej skrzynki”. To może utrudniać ocenę ich decyzji (Molnar, C., 2020).


3. Dane i ich przygotowanie

3.1. Dane

Rozdział ten ma na celu opis procesu zbierania i przygotowania danych na potrzeby badania niniejszej pracy. Wykorzystany został zbiór danych „Fake Reviews Dataset” (Salminen, J. i in, 2022), który został stworzony na potrzeby podobnego badania, celem wykrywania sztucznie wygenerowanych opinii produktowych. Składa się z 40432 unikalnych opinii produktowych, gdzie 50% opinii umieszczonych w powyższym zbiorze danych jest prawdziwych (Rys. 2), zaciągnięte w sposób losowy z 10 najpopularniejszych kategorii Amazon US (Rys. 3) z oficjalnego zbioru danych publikowanego przez Amazon. Druga połowa danych została wygenerowana przez model językowy GPT i jest traktowana jako dane fałszywe. Zbiór danych jest różnorodny i zawiera opinie o różnych długościach (Rys. 4).


Każda z opinii jest opisana następującymi cechami:

- label – zmienna celu (CG – Computer Generated Review – opinia wygenerowana przez model językowy, OR – Original Review – opinia napisana przez człowieka),
- category – nazwa kategorii produktu, którego dotyczy opinia,
- rating – liczba od 1 do 5, przedstawiająca liczbową ocenę poszczególnej opinii,
- text – treść tekstowa umieszczonej recenzji.




Rysunek 2. Rozkład zmiennej objaśnianej.

Źródło: opracowanie własne.



Rysunek 3. Podział opinii według kategorii produktowych

Źródło: opracowanie własne.



Rysunek 4. Rozkład długości opinii pod względem ilości wyrazów

Źródło: opracowanie własne.

3.2. Wstępne przetwarzanie danych

Przed przystąpieniem do analizy i klasyfikacji tekstów, niezbędne jest odpowiednie przygotowanie danych (Nowak-Brzezińska, A., 2011). Proces wstępnego przetwarzania obejmuje czyszczenie, normalizację oraz przekształcanie tekstów opinii do formatu, który może być efektywnie analizowany przez algorytmy uczenia maszynowego, w tym metody oparte na NLP (Natural Language Processing) (Malak, P., 2010). Poniżej przedstawiono kroki, które zostały wykonane w ramach wstępnego przetwarzania danych.

3.2.1. Czyszczenie danych

Jako pierwszy etap przygotowania danych do dalszej analizy, zostało przeprowadzone usuwanie zbędnych elementów tekstów recenzji, które mogą zakłócać proces analizy.

Między innymi wykonano następujące manipulacje:

- Usunięcie znaków specjalnych: Usunięto znaki interpunkcyjne, symbole, piktogramy oraz inne znaki, które nie niosą istotnej informacji semantycznej.
- Usunięcie tak zwanych „stop words”: Eliminacja słów stopu (np. "and", "or", "the") jest kluczowa, ponieważ słowa te występują często, ale nie mają znaczącego wpływu na znaczenie tekstu.
- Normalizacja wielkości liter: Wszystkie znaki zostały zamienione na małe litery, aby uniknąć rozróżniania słów ze względu na wielkość liter.
- Lematyzacja: Słowa zostały sprowadzone do ich podstawowej formy (lematu), co pozwala na grupowanie różnych form tego samego słowa (np. "working", "worked" → "work").

3.2.2. Tokenizacja

Teksty opinii zostały podzielone na pojedyncze tokeny (słowa lub wyrażenia), co jest niezbędne do dalszej analizy. Tokenizacja pozwala na przekształcenie ciągów znaków w listy słów, które mogą być przetwarzane przez algorytmy NLP (Grefenstette, G., 1999).

3.2.3. Przekształcenie tekstów do formatu numerycznego

Aby możliwe było zastosowanie algorytmów uczenia maszynowego, teksty zostały przekształcone do postaci numerycznej. W niniejszej pracy wykorzystano trzy główne podejścia:

Pierwszym podejściem jest TF-IDF. TF-IDF (ang. Term Frequency-Inverse Document Frequency): Metoda ta przekształca teksty w wektory numeryczne, uwzględniając częstotliwość występowania słów w dokumencie (TF) oraz ich znaczenie w kontekście całego zbioru danych (IDF). TF-IDF pozwala na wyznaczenie ważności słów w kontekście całego korpusu tekstów (Ramos, J., 2003).

Wartość TF oblicza się ze wzoru:

$$(tf - idf)_{i,j} = tf_{i,j} * idf_i,$$

gdzie $tf_{i,j}$ to tzw. „term frequency”, wyrażana wzorem:

$$tf_{i,j} = \frac{n_{i,j}}{\sum_k n_{k,j}},$$

gdzie $n_{i,j}$ jest liczbą wystąpień termu t_i w dokumencie d_j , a mianownik jest sumą liczby wystąpień wszystkich termów w dokumencie d_j . Wielkość idf_i to „inverse document frequency” wyrażana wzorem:

$$idf_i = \log \left(\frac{|D|}{|\{d : t_i \in d\}|} \right),$$

gdzie

$|D|$ – liczba dokumentów w korpusie tekstu,

$|\{d : t_i \in d\}|$ – liczba dokumentów zawierających co najmniej jedno wystąpienie danego termu.

Przekształcone wektory TF-IDF są następnie wykorzystywane jako dane wejściowe dla tradycyjnych algorytmów uczenia maszynowego, takich jak regresja logistyczna, Las Losowy.

Drugim podejściem przekształcania tekstu były Word Embeddings. Word Embeddings to zaawansowana technika reprezentacji tekstu, w której słowa są przekształcane w wektory o stałej długości w przestrzeni ciągłej (Peleвина, M. i in., 2017). Takie reprezentacje pozwalają na uchwycenie semantycznych i syntaktycznych zależności między słowami, co czyni je bardziej efektywnymi w zadaniach przetwarzania języka naturalnego. Word Embeddings, w połączeniu z sieciami neuronowymi, stanowią podstawę nowoczesnych systemów przetwarzania języka

naturalnego, umożliwiając bardziej precyzyjne modelowanie znaczenia tekstu niż tradycyjne metody, takie jak TF-IDF.

Ostatnim podejściem do przekształcania tekstów było wykorzystanie modelu BERT (ang. Bidirectional Encoder Representations from Transformers): model ten wykorzystuje architekturę transformerów do generowania kontekstowych osadzeń słów (Gardazi, N. M. i in., 2025). BERT analizuje tekst w sposób dwukierunkowy, co pozwala na lepsze zrozumienie kontekstu słów w zdaniu. W pracy wykorzystano wstępnie wytrenowany model BERT, który został dostrojony do zadania klasyfikacji tekstów. Teksty są tokenizowane za pomocą tokenizera BERT, a następnie przekształcane w wektory, które są przesyłane do modelu.

4. Wybrane metody wykrywania fałszywych opinii

4.1. Metody klasyczne


4.1.1. Regresja logistyczna

Regresja logistyczna jest szczególnym przypadkiem regresji liniowej. W praktyce, regresja logistyczna jest wykorzystywana do rozwiązywania problemów klasyfikacji z liniowo rozdzielonymi klasami (Hosmer, D. i in., 2000), co dokładnie odpowiada zagadnieniu przedstawionemu w tej pracy problemu klasyfikacji binarnej (fałszywa albo prawdziwa opinia).

Funkcja logistyczna lub krzywa logistyczna to krzywa w kształcie litery S (krzywa sigmoidalna) o równaniu:

$$f(x) = \frac{L}{1 + e^{-kx}}$$

gdzie k to współczynnik dla zmiennej x , który odpowiada za logistyczne tempo wzrostu, stromość krzywej; x to zmienna objaśniająca; L to supremum wartości funkcji, czyli wartość maksymalna i minimalna (Rys. 5).



Rysunek 5 Graficzne przedstawienie funkcji logistycznej

Źródło: opracowanie własne.

Sformułowanie problemu w przypadku wykorzystania regresji logistycznej wygląda następująco:

Założmy, że mamy pewien zbiór danych składający się z elementów postaci $\mathbf{x} = (\mathbf{x}_1, \dots, \mathbf{x}_m)$, gdzie m jest liczbą różnych zmiennych, które opisują pewną cechę rozważanych obiektów lub obserwacji.

Mamy na celu stworzenie modelu opartego na regresji logistycznej pewnej zmiennej zależnej y na zbiorze zmiennych niezależnych $\mathbf{x} = (\mathbf{x}_1, \dots, \mathbf{x}_m)$. Również mamy znane wartości wejściowe $\mathbf{x}_i$ i odpowiadające im rzeczywiste wartości wyników dla zmiennej zależnej dla każdej obserwacji $i = 1, \dots, n$, gdzie n oznacza liczbę obserwacji.

Celem jest znalezienie takiej funkcji regresji logistycznej P , aby przewidywane znaczenia $P(\mathbf{x}_i)$ były jak najbliżej rzeczywistej odpowiedzi y_i dla każdej obserwacji $i=1, \dots, n$. Musimy pamiętać, że rzeczywista odpowiedź może wynosić tylko 0 lub 1 w zadaniach klasyfikacji binarnej. Oznacza to, że każda wartość $P(\mathbf{x}_i)$ musi być bliska 0 lub 1.

Jeśli mamy funkcję regresji logistycznej $P(\mathbf{x})$, możemy jej użyć do przewidywania danych wyjściowych dla nowych danych wejściowych, które nie były zaangażowane w szkolenie modelu, pod warunkiem, że podstawowa zależność matematyczna nie uległa zmianie.

Warunki konieczne do zastosowania regresji logistycznej:

- Próba składa się z niezależnych obserwacji,
- Pomiędzy cechami nie występuje współliniowość,
- Wystarczająca liczebność próby
- Próba nie zawiera wielu wartości odstających.

Jednocześnie do regresji liniowej, dla algorytmu regresji logistycznej ważne jest, aby cechy miały tę samą skalę (Kleinbaum, D.G., Klein, M., 2010).

W procesie trenowania regresji logistycznej jest stosowana logistyczna funkcja błędu lub binarna entropia krzyżowa. Model jest optymalizowany przy użyciu metody maksymalnego prawdopodobieństwa w celu znalezienia optymalnego obszaru rozróżnienia między klasami. Funkcja ta mierzy różnicę pomiędzy przewidywanymi prawdopodobieństwami a rzeczywistymi klasami.

Wzór na błąd logistyczny jest następujący:

$$L(O, T) = \frac{1}{n} \sum_{i=1}^n -(t_i \log(o_i) - (1 - t_i) \log(1 - o_i))$$

gdzie O - wektor odpowiedzi modelu dla każdego wejściowego wektora cech, T -

wektor rzeczywistych wartości.

Jeżeli wartość prognozowana modelu będzie równa 1, $\log(1 - o_i)$ będzie błędne. Analogiczna sytuacja będzie występować dla $\log(o_i)$ w przypadku wartości prognozowanej równej 0. Żeby pozbyć się takich sytuacji wartość 1 jest zastępowana na 0,99, a wartość 0 na 0,01.

Wartość prognozowana modelu:

$$o = \frac{1}{(1 + e^z)}$$

z – liniowa kombinacja danych wejściowych oraz współczynników regresji.

Pochodna funkcji błędu logistycznego

$$L'_{wj} = \frac{x_{ij}(o_i - t_i)}{n},$$

$$L'_b = \frac{o_i - t_i}{n}$$

o – predykcje modelu na i-ty wektor cech, t - rzeczywista etykieta dla i-tego przykładu (0 lub 1), n – liczba przykładów w zbiorze danych.

4.1.2. Las Losowy

Las Losowy (ang. Random Forest) jest jednym z popularnych algorytmów uczenia maszynowego, który należy do klasy modeli zespołowych (ensemble learning). Jego mechanizm działania opiera się na wykorzystaniu wielu drzew decyzyjnych do podejmowania decyzji, co zwiększa stabilność i dokładność modelu w porównaniu do pojedynczych drzew decyzyjnych (Rigatti, S. J., 2017).

Las Losowy działa na konstrukcji drzew decyzyjnych, przy czym każde z tych drzew jest trenowane na losowym podzbiorze danych treningowych oraz z ograniczoną liczbą losowo wybranych cech. Każde drzewo generuje swoją własną prognozę, a końcowa klasa predykcji jest wybierana za pomocą głosowania większościowego.

Główną zaletą tego algorytmu jest ten fakt, że za pomocą mechanizmu losowania próbek i cech do wytrenowania poszczególnych drzew redukuje się problem przeuczenia modelu (ang. overfitting) i sprawia, że model jest bardziej odporny na szum i wartości odstające w danych (Breiman, L., 2001).

W przypadku klasyfikacji binarnej, gdzie wartość y przyjmuje wartości 0 lub 1, model Las Losowy tworzy wiele drzew decyzyjnych, a następnie dokonuje predykcji poprzez agregację wyników wszystkich drzew w następujący sposób:

$$P_{(y=1|x)} = \frac{1}{T} \sum_{t=1}^T h_t(x)$$

gdzie:

- T – liczba drzew w lesie
- $h_t(x)$ – rezultat prognozy dla t -ego drzewa.

Jak było wspomniano wcześniej, końcowa decyzja modelu jest podejmowana w sposób głosowania większościowego. Przedstawia się to w taki sposób:

$$\hat{y} = \underset{c}{\operatorname{argmax}} \sum_{t=1}^T 1(h_t(x) = c)$$

gdzie c – jedna z możliwych prognozowanych klas (0 lub 1).

4.2. Sieci neuronowe

4.2.1. LSTM

LSTM (ang. Long-Short-Term Memory) jest szczególny rodzaj rekurencyjnej sieci neuronowej (ang. Recurrent Neural Networks). Jedną z atrakcyjnych idei RNN jest to, że potencjalnie są one w stanie powiązać poprzednie informacje z bieżącymi, przez zdolność przechowywania „pamięci” o wcześniejszych danych wejściowych (Sherstinsky, A., 2020). Sieci RNN są potężnym narzędziem do analizy danych sekwencyjnych, jednak ich trenowanie wiąże się z wyzwaniami.

Dwa główne problemy dotyczące RNN, to zanikanie gradientu oraz jego eksplozja. Zanikanie gradientu polega na tym, że podczas propagacji wstecznej wartości pochodnych funkcji straty względem wag ulegają systematycznemu zmniejszaniu się. W efekcie wcześniejsze stany w sekwencji dają bardzo słaby wpływ na wynik końcowy. To sprawia, że klasyczne RNN mają trudności z uchwyceniem długoterminowych zależności. Z kolei eksplozja gradientu to sytuacja odwrotna. W tym przypadku wartości pochodnych rosną zbyt gwałtownie, co prowadzi do niestabilnego procesu uczenia.

Teoretycznie sieci RNN nie powinny mieć problemu z przetwarzaniem długoterminowych zależności. Człowiek może precyzyjnie dobrać parametry sieci do rozwiązywania sztucznych problemów tego typu. Niestety, w praktyce wytrenowanie sieci RNN z takimi parametrami wydaje się niemożliwe. Problem ten był szeroko badany (Hochreiter, S., 1991), znaleziono przekonujące powody, dla których może to

być trudne.

W przeciwieństwie do klasycznych RNN, modele LSTM potrafią przechowywać informacje przez długi czas (Staudemeyer, R. C., i Morris, E. R., 2019). Struktura LSTM składa się z komórek pamięci, które są sterowane przez tzw. „bramki”: bramkę zapominania, bramkę wejścia oraz bramkę wyjścia. Ich zadaniem jest kontrolowanie przepływu informacji w czasie. Polega to na podziale danych na te, które powinny zostać zapamiętane, które zapomniane, a które użyte do obliczeń (Yu, Y. i in., 2019).

Poniżej zostały przedstawione równania definiujące komórkę LSTM.

$$f_t = \sigma(W_f(h_{t-1}, x_t) + b_f)$$

$$i_t = \sigma(W_i(h_{t-1}, x_t) + b_i)$$

$$o_t = \sigma(W_o(h_{t-1}, x_t) + b_o)$$

$$C_t = f_t * C_{t-1} + i_t * \tanh(W_c(h_{t-1}, x_t) + b_c)$$

$$h_t = o_t * \tanh(C_t)$$

gdzie:

- h_t – stan ukryty w czasie t ,
- C_t – stan komórki w czasie t ,
- σ – funkcja sigmoidalna,
- W i b – macierze wag oraz wektory biasów do każdej bramki.

4.3. Transformery

4.3.1. BERT

BERT (ang. Bidirectional Encoder Representations from Transformers) to jedna z najbardziej nowoczesnych architektur wykorzystywanych w celu przetwarzania języka naturalnego (Koroteev, M.V., 2021). Model ten oparty jest na mechanizmie transformera oraz charakteryzuje się na dwukierunkowym przetwarzaniem wyrazów w zdaniu (Jawahar, G i in., 2019), co umożliwia osiągnięcie bardzo dobrych wyników w zadaniach analizy treści tekstowych.

Model BERT został wstępnie wytrenowany na dużej ilości danych tekstowych, takich jak Wikipedia oraz BooksCorpus, w dwóch głównych zadaniach (Rogers, A. i in., 2021):

- Masked Language Modelling (MLM) – losowe maskowanie wyrazów w zdaniach oraz przewidywanie tych słów na bazie kontekstu

- Next Sentence Prediction (NSP) – ocean, czy drugie zdanie logicznie następuje po pierwszym.

Dzięki temu BERT nauczył się głęboko rozumieć język naturalny. Z kolei to umożliwia jego dostosowanie (ang. fine-tuning) do konkretnych problemów, np. problem klasyfikacji fałszywych opinii, który jest opisany w niniejszej pracy.

4.4. Metody oceny modeli

4.4.1. Macierz pomyłek

W przypadkach oceny modeli klasyfikacji, do których możemy odnieść wszystkie modele przedstawione w niniejszej pracy, wykorzystywana jest macierz pomyłek (ang. Confusion Matrix) (Susmaga, R., 2004). Macierz pomyłek pokazuje, ile razy model poprawnie i błędnie sklasyfikował obiekty dla każdej klasy. W przypadku problemu klasyfikacji fałszywych opinii (klasyfikacji binarnej) struktura macierzy przedstawia się tak, jak to jest pokazane w Tabeli 1:

Tabela 1 Struktura macierzy pomyłek dla klasyfikacji binarnej

	Przewidziane pozytywne	Przewidziane negatywne
Rzeczywiste pozytywne	TP (True Positive)	FN (False Negative)
Rzeczywiste negatywne	FP (False Positive)	TN (True Negative)

Źródło: opracowanie własne.

- TP (ang. True Positive, prawdziwie pozytywne) – przypadki, gdy model poprawnie przewidział pozytywną klasę.
- TN (ang. True Negative, prawdziwie negatywne) – przypadki, gdy model poprawnie przewidział negatywną klasę.
- FP (ang. False Positive, fałszywie pozytywne, błąd I rodzaju) – przypadki, gdy model błędnie przewidział pozytywną klasę dla obiektu, który faktycznie należy do klasy negatywnej.

- FN (ang. False Negative, fałszywie negatywne, błąd II rodzaju) – przypadki, gdy model błędnie przewidział negatywną klasę dla obiektu, który faktycznie należy do klasy pozytywnej.

4.4.2. Metryki jakości klasyfikacji

W przypadku problemu klasyfikacji wykorzystywane następujące główne miary jakości modelu (Lever, J, 2016; Hossin, M., i Sulaiman, M. N., 2015):

1. Dokładność (ang. Accuracy)

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Dokładność pokazuje odsetek poprawnie sklasyfikowanych przypadków w odniesieniu do całkowitej liczby obserwacji. Jest użyteczna w przypadku dobrze zbilansowanych zbiorach danych (Olson, D. L., 2004).

2. Precyzja (ang. Precision, dokładność dla klasy pozytywnej)

$$Precision = \frac{TP}{TP + FP}$$

Wskazuje, jaki odsetek obiektów przewidzianych jako pozytywne rzeczywiście należy do klasy pozytywnej. Ważna w sytuacjach, gdzie błędne przewidywania pozytywne są kosztowne (Westgard, J. O. i Lott, J. A. 1981).

3. Czulość (ang. Recall)

$$Recall = \frac{TP}{TP + FN}$$

Pokazuje, jaki odsetek rzeczywiście pozytywnych obiektów został poprawnie sklasyfikowany. Jest kluczowa w zadaniach, gdzie fałszywie negatywne przewidywania są niepożądane.

4. Specyficzność (ang. Specificity)

$$Specificity = \frac{TN}{TP + FP}$$

Specyficzność mierze zdolność modelu do poprawnego identyfikowani negatywnych przypadków.

W przypadku problemu klasyfikacji fałszywych opinii oraz biorąc pod uwagę ten fakt, że analizowany zbiór danych jest dobrze zbilansowany, uważam, że


priorytetowymi metrykami do porównania modeli będą dokładność oraz czułość (mamy na celu minimalizację błędów II rodzaju).

4.4.1. Krzywa ROC oraz miara AUC

Krzywa ROC (ang. Receiver Operating Characteristic) to wykres, który przedstawia zdolność modelu do rozróżniania klas w zależności od różnych progów decyzyjnych (Rys. 6) (Metz, C. E., 1978).

Na osiach znajdują się:

- Oś X: False Positive Rate – odsetek fałszywie pozytywnych klasyfikacji
- Oś Y: True Positive Rate – czułość.



73

Rysunek 6 Krzywa ROC oraz pole pod krzywą,

Źródło: Mathematics Journal (<https://www.researchgate.net/journal/Mathematics-2227-7390>)

Miara AUC (ang. Area Under Curve) oznacza pole pod krzywą ROC i określa skuteczność modelu w rozróżnianiu klas.

Interpretacja wartości AUC:

- $AUC = 0,5$ – model losowy, nie ma zdolności do rozróżniania klas.
- $AUC < 0,5$ – model działa gorzej niż losowe przewidywanie.
- $AUC > 0,5$ – model ma dodatnią zdolność do wykrywania klas.
- $AUC = 1$ – model idealnie rozróżnia klasy

5. Implementacja i eksperymenty

W niniejszym rozdziale został przedstawiony proces implementacji wybranych modeli uczenia maszynowego. Jednocześnie, zostały opisane eksperymenty, mające na celu wybór najlepszych hiperparametrów poszczególnych algorytmów oraz wybór najlepszego modelu w zadaniu wykrywania fałszywych opinii. Dla każdego z testowanych modeli przeprowadzono walidację krzyżową (ang. cross-validation), której celem było zapewnienie, że model ma dobrą zdolność do generalizacji i jest stabilny. Ostateczna ocena skuteczności modeli została dokonana na podstawie dwóch metryk: Dokładność oraz AUC. Porównując wyniki poszczególnych algorytmów, wybrano najlepszy model klasyfikacyjny dla danego problemu.

5.1. Regresja logistyczna

5.1.1. Dobór hiperparametrów

W przypadku doboru najlepszych parametrów dla regresji logistycznej zostały przetestowane różne kombinacje dwóch parametrów:

- c – parametr odwrotności siły regularyzacji (większa wartość odpowiada słabszej regularyzacji),
- solver – algorytm optymalizacji wykorzystywany do dopasowania modelu (liblinear, lbfgs).

Dla każdej kombinacji parametrów wyznaczono średnią dokładność (ang. mean accuracy), a następnie przypisano ranking na podstawie skuteczności klasyfikatora.

Tabela 2 Przetestowane kombinacje hiperparametrów (Regresja logistyczna)

param_C	param_solver	Mean Accuracy	rank_test_score
0.01	liblinear	0.7911887468853219	15
0.01	lbfgs	0.7908795810451154	16
0.1	liblinear	0.8332045087369911	13
0.1	lbfgs	0.8328953314263371	14
1.0	liblinear	0.8722522836843787	11
1.0	lbfgs	0.8716648648600906	12
3.0	liblinear	0.8762714424746761	5
3.0	lbfgs	0.8757458694359217	9
4.0	liblinear	0.8765188055435273	3
4.0	lbfgs	0.8768589014455305	2
5.0	liblinear	0.8770753172469138	1
5.0	lbfgs	0.8762406127792955	6
8.0	liblinear	0.8762715485763158	4
8.0	lbfgs	0.8761169470167353	7
10.0	liblinear	0.8759005226125162	8
10.0	lbfgs	0.8756531968226194	10

Źródło: opracowanie własne.

Zmiana parametrów mocno wpłynęła na wynikową efektywność modeli. Najlepszy wynik uzyskano dla pary parametrów $c = 5$ oraz solver = liblinear, osiągając średnią dokładność na poziomie 0.8771. Niewiele gorsze rezultaty uzyskano dla:

- $c = 4$, solver = (lbfgs, liblinear) – dokładność 0,8769 oraz 0,8765
- $c = 8$, solver = liblinear – dokładność 0,8763

Jednocześnie najniższe wyniki osiągnięto przy bardzo małych wartościach $c = 0,01$.


Analiza wyników wskazuje, że zwiększenie wartości c (czyli słabsza regularyzacja) poprawia skuteczność klasyfikatora, różnice między solverami są nieznaczne. Zarówno liblinear, jak i lbfgs dawały porównywalne wyniki.

Na podstawie przeprowadzonych testów do dalszej analizy wybrano model o najlepszym zestawie hiperparametrów ($c = 5$, solver = liblinear).

5.1.2. Analiza macierzy pomyłek


Wyniki na zbiorze treningowym (Rys. 7) pokazują, że model osiągnął bardzo dobrą skuteczność na danych, na których się uczył. Model bardzo dobrze rozróżnia obie klasy recenzji – fałszywą oraz prawdziwą. Jednocześnie liczba błędnych klasyfikacji

jest relatywnie niska do ogólnej liczby próbek. Dokładność na zbiorze treningowym wyniosła 92,7%.



Rysunek 7 Macierz pomyłek dla zbioru treningowego, regresja logistyczna
Źródło: opracowanie własne

W przypadku zbioru testowego (Rys. 8) model utrzymuje wysoką jakość predykcji, co świadczy o dobrej zdolności modelu do generalizacji. Wyniki są bardzo zbliżone dla obu klas, co sugeruje, że model jest dobrze zbilansowany i nie traktuje priorytetowo jedną z klas. Dokładność na zbiorze testowym wyniosła 88,6%.




Rysunek 8 Macierz pomyłek dla danych testowych (Regresja logistyczna)
Źródło: opracowanie własne

Podsumowując możemy stwierdzić, że model wskazuje wysoką skuteczność na obu zbiorach, co oznacza, że nie nastąpiło przeuczenie.

5.1.1. Analiza krzywej ROC

Na poniższym rysunku (Rys. 9) została przedstawiona krzywa ROC dla analizowanego klasyfikatora.



Rysunek 9 Krzywa ROC oraz metryki AUC dla zbiorów treningowego i testowego
Źródło: opracowanie własne

Model osiąga znakomitą skuteczność na zbiorze treningowym, jak i testowym, co potwierdzają wysokie wartości AUC. Ma bardzo dobrą zdolność do rozróżniania klas i charakteryzuje się stabilnym działaniem bez istotnego spadku na danych testowych.

5.2. Las Losowy

5.2.1. Dobór hiperparametrów

W celu optymalizacji działania algorytmu Las Losowy przeprowadzono strojenie hiperparametrów z wykorzystaniem walidacji krzyżowej.

Rozważane były trzy parametry:

- `n_estimators` – liczba drzew w lesie losowym (wartości: 100, 200)
- `min_samples_split` – minimalna liczba obserwacji wymagana do podziału węzła (wartości 2, 5, 7)
- `min_samples_leaf` – minimalna liczba próbek w liściu (wartości: 5, 7)

Dla każdej kombinacji tych parametrów obliczono średnią dokładność (ang. mean accuracy) na podzbiorach testowych, a wyniki zostały uszeregowane według skuteczności.

Tabela 3 Przetestowane kombinacje hiperparametrów (Las Losowy)

param_n_estimators	min_samples_split	min_samples_leaf	Mean Accuracy	rank_test_score
100	2	5	0.819570224	4
200	2	5	0.822445472	1
100	5	5	0.819570224	4
200	5	5	0.822445472	1
100	10	5	0.819570224	4
200	10	5	0.822445472	1
100	2	7	0.814098009	10
200	2	7	0.815922014	7
100	5	7	0.814098009	10
200	5	7	0.815922014	7
100	10	7	0.814098009	10
200	10	7	0.815922014	7

Źródło: opracowanie własne.

Najlepsze rezultaty uzyskano dla parametrów 'min_samples_leaf': 5, 'min_samples_split': (2, 5, 10), 'n_estimators': 200; gdzie średnia dokładność wyniosła 0,8224. Te kombinacje dostały pierwsze miejsce w rankingu.


Z kolei najniższa skuteczność algorytmu została zaobserwowana min_samples_leaf:7, n_estimators: 100. W tym przypadku średnia dokładność wyniosła około 0,8141.

Wyniki te sugerują, że zwiększenie liczby estymatorów (drzew) oraz zastosowanie mniejszej liczby próbek w liściu wpływa pozytywnie na jakość klasyfikatora na bazie Lasów Losowych. Ostatecznie, na podstawie przedstawionych wyników, do dalszych analiz wybrano najlepszą konfigurację parametrów.

5.2.2. Analiza macierzy pomyłek

Wyniki na zbiorze treningowym (Rys.10) pokazują, że model osiągnął bardzo


dobrą skuteczność na danych, na których się uczył. Model bardzo dobrze rozróżnia obie klasy recenzji – fałszywą oraz prawdziwą. Jednocześnie liczba błędnych klasyfikacji jest relatywnie niska do ogólnej liczby próbek. Dokładność na zbiorze treningowym wyniosła 88%.



Rysunek 10 Macierz pomyłek dla danych treningowych, Las Losowy

Źródło: opracowanie własne

W przypadku zbioru testowego (Rys. 11) model utrzymuje wysoką jakość predykcji, chociaż myli się nieco częściej. Dokładność na zbiorze testowym wyniosła 84%. Może to świadczyć o lekkim przeuczeniu modelu.




Rysunek 11 Macierz pomyłek dla danych testowych, Las Losowy

Źródło: opracowanie własne

Zarówno na zbiorze treningowym, jak i testowym model jest skuteczny w wykrywaniu klas. Jednak jest nieco lepszy w wykrywaniu klasy 0 (prawdziwej recenzji).

5.2.3. Analiza krzywej ROC

Na poniższym wykresie przedstawiono krzywe ROC uzyskane dla modelu na zbiorze treningowym oraz testowym.



Rysunek 12 Krzywa ROC oraz metryki AUC dla zbiorów treningowego i testowego, Las Losowy

Źródło: opracowanie własne

Linia niebieska (krzywa treningowa) ma pole pod krzywą (AUC) równe 0,95, co świadczy o bardzo dobrej jakości modelu na danych uczących. Linia pomarańczowa (krzywa testowa) również potwierdza wysoką zdolność modelu do poprawnej klasyfikacji na nowych danych.

Można powiedzieć, że model osiąga dobrą skuteczność na danych treningowych oraz testowych. Istnieje niewielka różnica pomiędzy AUC na treningowym a testowym, ale jest ona akceptowalna i nie wskazuje istotnego przeuczenia.

5.3. LSTM

5.3.1. Dobór hiperparametrów

W celu optymalizacji działania sieci neuronowej LSTM oraz uzyskania najlepszych wyników klasyfikacji za jej pomocą przeprowadzono proces doboru hiperparametrów. Skupiono się na czterech głównych parametrach sieci:

- liczbie jednostek w pierwszej warstwie LSTM (lstm_1_units),
- wartości dropout po tej warstwie (dropout_1),
- liczbie jednostek w drugiej warstwie LSTM (lstm_2_units),
- wartości dropout po drugiej warstwie LSTM (dropout_2).

Tabela 4 przedstawia wyniki testów 22 konfiguracji modelu. Jako metryka decydująca o jakości modelu, została wybrana dokładność na zbiorze testowym. Najlepszy wynik walidacyjny uzyskano dla konfiguracji:

- lstm_1_units = 128,
- dropout_1 = 0,5
- lstm_2_units = 64
- dropout_2 = 0,3

Tabela 4 Przetestowane hiperparametry, LSTM

trial_id	lstm_1_units	dropout_1	lstm_2_units	dropout_2	val_accuracy
0016	128	0,5	64	0,3	0,923414767
0017	128	0,5	32	0,3	0,923414767
0015	128	0,5	64	0,3	0,895690382
0020	64	0,5	32	0,5	0,888004363
0006	64	0,5	32	0,3	0,679385126
0001	128	0,5	32	0,3	0,639308274
0010	128	0,3	32	0,5	0,638759255
0013	128	0,5	32	0,3	0,6222893
0002	128	0,5	64	0,3	0,609662354
0014	128	0,3	32	0,5	0,598682404
0018	128	0,5	64	0,5	0,589623928
0012	64	0,5	32	0,3	0,557782054
0007	64	0,5	64	0,5	0,556135058
0005	64	0,3	64	0,5	0,550919592
0009	128	0,3	64	0,3	0,541037619
0000	128	0,3	64	0,5	0,531704664
0004	128	0,3	32	0,3	0,530606627
0021	64	0,3	32	0,5	0,5185287
0019	128	0,5	32	0,5	0,511666238
0003	64	0,3	32	0,3	0,500411749
0008	64	0,5	64	0,3	0,500411749
0011	64	0,3	64	0,3	0,499588251

Źródło: opracowanie własne.

Eksperymenty pokazują, że większą skuteczność osiągały modele o większej liczbie neuronów w pierwszej warstwie LSTM i stosunkowo wysokiej wartości dropout po tej warstwie, który zapobiegał przeuczeniu. Z kolei liczba jednostek w drugiej warstwie sieci miała mniejszy wpływ na skuteczność modelu.

5.3.2. Uczenie najlepszego modelu

Z wykorzystaniem wybranych wcześniej najlepszych parametrów model został wytrenowany w czasie siedmiu epok. Podczas trenowania modelu monitorowano dokładność (ang. accuracy), jak i funkcję kosztu/straty (ang. loss) dla zbioru treningowego i testowego. Zostało to przedstawiono na odpowiednich wykresach (Rys. 13).


W pierwszej epoce model osiągnął niską dokładność treningową i stratę na poziomie 0,6, natomiast już po tej epoce została zaobserwowana dokładność około 85% na danych testowych.

W kolejnych epokach obserwowano dalszą poprawę wyników – po trzeciej epoce został odnotowany najlepszy wynik:

- dokładność na zbiorze testowym – 93,88%
- strata na zbiorze testowym – 0,158

Choć dokładność treningowa stale rosła, aż do poziomu 98% w ostatniej epoce, nie wykryto już poprawy wyników na danych testowych po trzeciej epoce. Świadczy to o tym, że w tym momencie rozpoczął się proces przeuczenia modelu. Ten fakt również potwierdza wzrastająca różnica pomiędzy stratą treningową i testową w kolejnych epokach.

Ostatecznie jako najlepszy model wybrano wersję zapisaną po trzeciej epoce. Model ten został użyty do dalszych analiz i testowania.




Rysunek 13 Przebieg uczenia sieci LSTM, 1 - zmiana dokładności na zbiorach testowym i walidacyjnym, 2 - zmiana straty na zbiorach testowym i walidacyjnym

Źródło: opracowanie własne


5.3.3. Analiza macierzy pomyłek

Wyniki na zbiorze treningowym (Rys.14) pokazują, że model osiągnął bardzo dobrą skuteczność na danych, na których się uczył. Model bardzo dobrze rozróżnia obie klasy recenzji – fałszywą oraz prawdziwą. Jednocześnie liczba błędnych klasyfikacji jest relatywnie niska do ogólnej liczby próbek. Dokładność na zbiorze treningowym wyniosła 96,7%.



Rysunek 14 Macierz pomyłek dla zbioru treningowego, LSTM

Źródło: opracowanie własne



Rysunek 15 Macierz pomyłek dla zbioru testowego, LSTM

Źródło: opracowanie własne

W przypadku zbioru testowego (Rys. 15) model utrzymuje wysoką jakość predykcji, chociaż myli się nieco częściej. Dokładność modelu na zbiorze testowym wyniosła 93,8%. Może to świadczyć o lekkim przeuczeniu modelu. Wyniki są bardzo zbliżone dla obu klas, co sugeruje, że model jest dobrze zbilansowany i nie traktuje priorytetowo jedną z klas.


Podsumowując, można powiedzieć, że opracowany model pokazuje dobrą skuteczność zarówno na danych uczących i testowych. Lekki spadek skuteczności modelu na danych testowych może świadczyć o lekkim przeuczeniu modelu.

5.3.4. Analiza krzywej ROC

Na poniższym rysunku została przedstawiona krzywa ROC dla analizowanego klasyfikatora.

Niebieska krzywa (dla zbioru treningowego) wskazuje na niemal idealną zdolność modelu do rozróżniania klas. $AUC \approx 1$ potwierdza to, że model osiągnął prawie idealną skuteczność na danych, na których się uczył.

Pomarańczowa linia (dla zbioru testowego) również wskazuje na bardzo dobre właściwości klasyfikacyjne modelu na nowych danych.



Rysunek 16 Krzywe ROC oraz metryki AUC dla zbiorów treningowego i testowego, LSTM

Źródło: opracowanie własne

Można powiedzieć, że model wykazuje bardzo wysoka skuteczność na zbirze treningowym oraz testowym. $AUC \approx 1$ na danych treningowych może świadczyć o lekkim przeuczeniu modelu, jednak $AUC \approx 0,98$ na zbiorze testowym nadal potwierdza wysoką zdolność do generalizacji.

5.4. BERT

5.4.1. Dobór hiperparametrów

Ze względu na ograniczone zasoby czasowe oraz obliczeniowe a jednocześnie wysokie wymagania obliczeniowe związane z uczeniem modeli typu BERT, zostało przyjęte realistyczne podejście. Znaczy to, że proces doboru hiperparametrów został przeprowadzony w sposób uproszczony oraz został oparty na rekomendacjach wcześniej opisanych w literaturze (Zhou, Y., & Srikumar, V., 2021); (Merchant, A i in., 2020); (Sun, C. I in., 2019).

Przeprowadzono dobór parametrów wstępnie trenowanego modelu BERT (ang. bert-base-uncased), testując wybrane konfiguracje parametrów. W szczególności badano wpływ sposobu tokenizacji (padding = 'max_length' oraz 'longest') oraz

wartości współczynnika uczenia (ang. learning rate: 2e-5, 2e-4, 3e-5).

Każda konfiguracja została oceniona po jednej epoce uczenia. Ocena modeli polegała na porównywaniu metryk straty na zbiorach testowym i treningowym, dokładności na zbiorze testowym. Wyniki zostały przedstawione w Tabeli 5.

Tabela 5 Przetestowane parametry do uczenia BERT

Tokenization Padding	Learning Rate	Epoki	Training Loss	Validation Loss	Accuracy	AUC
max length	2e-4	1	0.280	0.207318	0.913	0.975
longest	2e-5	1	0.3655	0.322613	0.857	0.945
longest	3e-5	1	0.4022	0.324610	0.863	0.946

Źródło: opracowanie własne.

Na podstawie uzyskanych wyników zauważono, że najlepsze rezultaty osiągnięto przy tokenizacji z dopełnianiem do maksymalnej długości (ang. max length) oraz zastosowaniu współczynnika uczenia (ang. learning rate) na poziomie 2e-4.

Taki model po pierwszej epoce uzyskał najwyższą dokładność (91,3%) na zbiorze testowym. Jednocześnie model ten uzyskał najwyższą wartość AUC na zbiorze testowym (0,975). Taka konfiguracja modelu została uznana za najlepszą oraz wybrana do dalszego uczenia i analizy.


5.4.2. Uczenie najlepszego modelu

Wybrany model o najlepszych wartościach hiperparametrów został trenowany przez trzy epoki w celu oceny procesu uczenia, jego dynamiki oraz identyfikacji potencjalnego punktu przeuczenia (ang. overfitting). Wyniki treningu zostały przedstawione w Tabeli 6 oraz na Rysunkach 17, 18.

Tabela 6 Przebieg trenowania modelu BERT


Epoch	Training Loss	Validation Loss	Accuracy	Auc
1	0.280000	0.207318	0.913000	0.975000
2	0.241500	0.202996	0.914000	0.977000
3	0.230000	0.219237	0.907000	0.974000

Źródło: opracowanie własne.



Rysunek 17 Przebieg uczenia modelu BERT, straty na zbiorach treningowym i testowym

Źródło: opracowanie własne.



Rysunek 18 Zmiana dokładności oraz AUC na zbiorze testowym podczas uczenia BERT

Źródło: opracowanie własne.

Przedstawione wyniki wskazują na poprawę jakości modelu na zbiorze walidacyjnym podczas pierwszych dwóch epok. Obserwowalny jest spadek wartości


straty oraz wzrost metryk dokładności oraz AUC. Jednak po trzeciej epoce nastąpiło słabe pogorszenie modelu (wyników walidacyjnych). Obserwowalny jest na tym etapie lekki wzrost wartości straty na zbiorze testowym oraz spadek metryk jakości (dokładność, AUC). Może to świadczyć o początku procesu przeuczenia.

Uznano, że optymalna liczba epok dla trenowania modelu przy danych parametrach wynosi 2 epoki. Dalsze zwiększanie liczby epok nie prowadziło do poprawy jakości modelu.

5.5. Analiza macierzy pomyłek


Wyniki na zbiorze treningowym (Rys.19) pokazują, że model osiągnął bardzo dobrą skuteczność na danych, na których się uczył. Model bardzo dobrze rozróżnia obie klasy recenzji – fałszywą oraz prawdziwą. Jednocześnie liczba błędnych klasyfikacji jest relatywnie niska do ogólnej liczby próbek.

Jednocześnie na danych testowych (Rys. 20) model pokazuje bardzo przybliżone wyniki. Czułość testowa na poziomie ~95% świadczy o tym, że BERT prawie idealnie rozpoznaje wygenerowane przez sztuczną inteligencję opinie. Również obserwowalny jest bardzo niski rozrzut pomiędzy wynikami na zbiorze treningowym a walidacyjnym. Wskazuje to na wyjątkową stabilność modelu.



Rysunek 19 Macierz pomyłek dla zbioru treningowego (BERT)

Źródło: opracowanie własne.




Rysunek 20 Macierz pomyłek dla zbioru testowego (BERT)

Źródło: opracowanie własne.

5.6. Analiza krzywej ROC

Krzywa ROC dla modelu BERT również potwierdza wcześniejsze obserwacje: krzywa ROC dla zbioru testowego jest niemal idealnie dopasowana do krzywej dla zbioru treningowego. Potwierdza to również metryka AUC, która jest taka sama dla obu zbiorów. Można stwierdzić, że model prawie nie stracił swojej siły do poprawnego klasyfikowania na nowych, wcześniej nie widzianych danych.



Rysunek 21 Krzywe ROC dla zbiorów testowego i treningowego (BERT)

Źródło: opracowanie własne.

5.7. Dyskusja wyników

W ramach przeprowadzonych eksperymentów porównano skuteczność czterech modeli zaprojektowanych na potrzeby wykrywania fałszywych opinii generowanych przez sztuczną inteligencję (klasa 1/CG), na tle opinii napisanych przez ludzi (klasa 0/OR).

Każdy model został oceniony z wykorzystanie metryk: dokładność (ang. accuracy), precyzja (ang. precision), czułość (ang. recall), specyficzność (ang. specificity) oraz AUC. W Tabeli 7 zestawiono wyniki osiągnięte przez wszystkie modele na zbiorze testowym.

Tabela 7 Podsumowanie wyników klasyfikacji dla opracowanych modeli na zbiorze testowym.

Model	Dokładność	Precyzja	Czułość	Specyficzność	AUC
Regresja logistyczna	88,65%	88,63%	88,67%	88,60%	0,96
Las Losowy	84,01%	85,66%	81,70%	90,53%	0,92
WE + LSTM	93,79%	92,81%	94,85%	92,01%	0,98
BERT	90,96%	87,69%	94,91%	83,46%	0,98

Źródło: opracowanie własne.

Model regresji logistycznej osiągnął dobre wyniki we wszystkich metrykach, co świadczy o jego stabilności i solidnej zdolności do generalizacji. Biorąc pod uwagę niską złożoność oraz wysoką interpretowalność tego modelu może być dobrym wyborem w tych przypadkach, gdzie ważna jest przejrzystość decyzji (np. komponent wspomagający lub klasyfikator bazowy). Niemniej jednak, na tle innych algorytmów, jego skuteczność w wykrywaniu fałszywych opinii jest ograniczona.

Model lasów losowych cechuje się wysoką specyficznością (90,53%). Oznacza to, że model bardzo dobrze rozpoznaje prawdziwe opinie oraz generuje mniej fałszywych alarmów. Jednak jego czułość jest najniższa spośród wszystkich analizowanych modeli. Model nie radzi sobie zbyt dobrze z wykrywaniem fałszywych opinii. Taki model może być odpowiednim rozwiązaniem tam, gdzie koszt błędnej klasyfikacji prawdziwej opinii jako fałszywej jest zbyt wysoki.

Sieć LSTM okazała się najskuteczniejszym algorytmem. Model ten osiągnął najwyższe wartości dokładności, precyzji, specyficzności, a także bardzo wysoką czułość. Z tego powodu model ten jest rekomendowany do zastosowań produkcyjnych, gdzie celem jest maksymalizacja ilości wykrytych fałszywych opinii przy jednoczesnym ograniczeniu błędów klasyfikacji prawdziwych treści.

W przypadku modelu BERT również zaobserwowane zostały bardzo wysokie wyniki metryk klasyfikacji. Model ten osiągnął najwyższą czułość spośród wszystkich analizowanych modeli. Jednocześnie pokazał najlepszą stabilność (różnice pomiędzy

zbiorem treningowym a testowym są minimalne), co wskazują na bardzo dobrą zdolność do generalizacji. Niemniej jednak, model ten uzyskał najniższą specyficzność. Skutkiem tego będzie zwiększenie liczby fałszywie pozytywnych klasyfikacji. Najprawdopodobniej, takie wyniki są skutkiem ograniczonej liczby eksperymentów z tym modelem. Przy bardziej dokładnym doborze hiperparametrów można byłoby uzyskać lepsze wyniki. Na tym etapie, opracowany model może być szczególnie przydatny w takim kontekście, gdzie wymagane jest wychwycenie jak największej liczby fałszywych opinii, nawet kosztem większej liczby fałszywych alarmów.

5.8. Potencjalne kierunki dalszych badań

Wyniki uzyskane w ramach przeprowadzonych eksperymentów wskazują na możliwe kierunki dalszych badań.

Przede wszystkim, należy zwrócić uwagę na ten fakt, że w ramach niniejszego badania został użyty zbiór danych, w którym podzbiór fałszywych (wygenerowanych) opinii składał się z opinii wygenerowanych przez model językowy GPT-2. Model ten dziś uznawany jest za przestarzały. Od czasu jego powstania pojawiło się wiele różnych bardziej zaawansowanych modeli (np. GPT-4o, Claude, Gemini), które generują teksty o znacznie wyższej jakości. Z tego powodu istotnym kierunkiem dalszych badań powinno być rozszerzenie wykorzystanego zbioru danych o opinie wygenerowane przez bardziej nowoczesne modele. Pozwoli to na bardziej dokładną ocenę skuteczności algorytmów w aktualnych warunkach rynkowych.

Drugim obszarem, który wymaga uwagi, jest model BERT opracowany w ramach tej pracy. Model ten osiągnął bardzo wysoką czułość, ale jednocześnie relatywnie niską specyficzność. Wynik ten najprawdopodobniej wynika z faktu, że model nie został poddany pełnej procedurze doboru hiperparametrów. Ze względu na ograniczone zasoby, jego trening został przeprowadzony tylko na kilku zestawach hiperparametrów. Można przypuszczać, że dokładniejsze strojenie takich hiperparametrów jak współczynnik uczenia, ilość danych czy strategia zamrażania warstw modelu mogłaby przynieść znacząco lepsze wyniki klasyfikacji. Warto także rozważyć zastosowanie bardziej zoptymalizowanych architektur, takich jak RoBERTa czy ALBERT.

Wreszcie, ciekawym kierunkiem rozwoju może być zastosowanie modeli uwzględniających nie tylko samą treść tekstową opinii, ale również metadane, takie jak ocena opinii, nazwa użytkownika, znacznik czasu opinii oraz inne.

6. Wnioski

W pierwszej kolejności warto podkreślić, że wyniki badania jednoznacznie potwierdzają wysoką skuteczność nowoczesnych modeli uczenia maszynowego oraz przetwarzania języka naturalnego do wykrywania fałszywych opinii w ECommerce. Niemniej jednak, zostały przedstawione miejsca ewentualnego polepszenia modeli oraz kierunki dalszych badań, które mogłyby polepszyć dotychczasowe wyniki.

Na podstawie przeprowadzonej analizy można stwierdzić, że model LSTM pozwala osiągnąć najlepszy ogólny rezultat, biorąc pod uwagę wszystkie metryki jakości klasyfikacji. Wysokie wartości czułości oraz precyzja tego modelu świadczą o mocnym potencjale modelu do zastosowania w praktyce.

Jednocześnie BERT jest silną alternatywą, zwłaszcza w scenariuszach wymagających najwyższej wykrywalności opinii wygenerowanych przez sztuczną inteligencję, przy jednocześnie wyższym poziomie fałszywych alarmów. Uważam, że cały potencjał tego modelu nie został wykorzystany oraz przy bardziej dokładnym doborze hiperparametrów dałoby się uzyskać lepsze wyniki.

Z kolei Las Losowy oraz regresja logistyczna mogą być stosowane w środowiskach o ograniczonych zasobach obliczeniowych, bądź tam, gdzie prostota oraz interpretowalność tych algorytmów jest kluczowa. Jednak w tym przypadku warto podkreślić ograniczoną zdolność tych modeli do detekcji fałszywych opinii.

7. Spis literatury

1. Karakaya F., Ganim Barnes N. 2010. Impact of online reviews of customer care experience on brand or company selection. *Journal of Consumer Marketing* 27(5): 447–457.
2. Cheng Y.H., Ho H.Y. 2015. Social influence's impact on reader perceptions of online reviews. *Journal of Business Research* 68(4): 883–887.
3. Liu M., Zhou M. 2012. Understanding the Impacts of Perceived Consumer Online Reviews on Consumer Purchase Intention. W: WHICEB 2012 Proceedings. Association for Information Systems. <https://aisel.aisnet.org/whiceb2011/51>
4. Akesson J., Hahn R.W., Metcalfe R.D., Monti-Nussbaum M. 2023. The impact of fake reviews on demand and welfare. Working Paper No. w31836, National Bureau of Economic Research.
5. Ostrowska I. 2010. Rekomendacje konsumenckie jako sposób pozyskiwania klientów w dobie kryzysu. *Zeszyty Naukowe Uniwersytetu Szczecińskiego. Ekonomiczne Problemy Usług* (46): 219–228.
6. Jindal N., Liu B. 2008. Opinion spam and analysis. W: *Proceedings of the 2008 International Conference on Web Search and Data Mining*, New York: 219–230.
7. Salminen J., Kandpal C., Kamel A.M., Jung S.G., Jansen B.J. 2022. Creating and detecting fake reviews of online products. *Journal of Retailing and Consumer Services* 64: 102771.
8. Ott M., Choi Y., Cardie C., Hancock J.T. 2011. Finding deceptive opinion spam by any stretch of the imagination. *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*: 309–319.
9. Mukherjee A., Liu B., Glance N. 2012. Spotting fake reviewer groups in consumer reviews. W: *Proceedings of the 21st International Conference on World Wide Web*, Lyon, France: 191–200.
10. Mayzlin D., Dover Y., Chevalier J.A. 2014. Promotional Reviews: An Empirical Investigation of Online Review Manipulation. *American Economic Review* 104(8): 13–14.

11. Ahmed H., Traore I., Saad S. 2018. Detecting opinion spams and fake news using text classification. *Security and Privacy* 1(1): e9.
12. Mahavidyalaya L.M.V., Izhar F. 2024. Issues related to fake reviews and deceptive marketing practices – an analytical study.
13. Siau K., Wang W. 2020. Artificial intelligence (AI) ethics: ethics of AI and ethical AI. *Journal of Database Management (JDM)* 31(2): 74–87.
14. Zielińska I. 2024. Informacja i dezinformacja. W: Wojtkowiak M. (red.) *Młodzież w infosferze*. Instytut Badań Edukacyjnych, Warszawa: 67–85.
15. Budzanowska-Drzewiecka M. 2023. Wiedza konsumentów o produkcie jako determinanta postrzegania przydatności recenzji internetowych o różnej walencji. *Marketing i Rynek* (6): 15–24.
16. Skowrońska J. 2024. Prawnokarne aspekty technologii wykorzystującej sztuczną inteligencję.
17. Szoszkiewicz Ł. 2021. Dostępność danych w czasach sztucznej inteligencji a prawa człowieka w dziedzinie nauki. Instytut Nauk Prawnych PAN.
18. Tom E., Keane P.A., Blazes M., Pasquale L.R., Chiang M.F., Lee A.Y., Force A.A.I.T. 2020. Protecting data privacy in the age of AI-enabled ophthalmology. *Translational Vision Science & Technology* 9(2): 36.
19. Zarsky T. 2016. The trouble with algorithmic decisions: An analytic road map to examine efficiency and fairness in automated and opaque decision making. *Science, Technology, & Human Values* 41(1): 118–132.
20. Verma S. 2019. Weapons of Math Destruction: How Big Data Increases Inequality and Threatens Democracy. *Vikalpa* 44(2): 97–98.
21. Molnar C. 2020. *Interpretable Machine Learning*. Lulu.com.
22. Hosmer D.W., Lemeshow S., Sturdivant R.X. 2000. *Applied Logistic Regression*. Hoboken.
23. Kleinbaum D.G., Klein M. 2010. *Introduction to Logistic Regression*. W: *Logistic Regression*, Springer, New York, NY.
24. Hochreiter S. 1991. *Untersuchungen zu dynamischen neuronalen Netzen*. Praca dyplomowa, TU Munich.
25. Hochreiter S., Schmidhuber J. 1997. Long short-term memory. *Neural Computation* 9(8): 1735–1780.
26. Nowak-Brzezińska A. 2011. *Przygotowanie danych w środowisku R*.

27. Grefenstette G. 1999. Tokenization. W: Syntactic Wordclass Tagging. Springer, Dordrecht: 117–133.
28. Ramos J. 2003. Using tf-idf to determine word relevance in document queries. W: Proceedings of the First Instructional Conference on Machine Learning 242(1): 29–48.
29. Pelevina M., Arefyev N., Biemann C., Panchenko A. 2017. Making sense of word embeddings. arXiv:1708.03390.
30. Malak P. 2010. Rozwój badań nad przetwarzaniem języka naturalnego. *Zagadnienia Informatyki Naukowej – Studia Informacyjne* (2(96)): 21–30.
31. Gardazi N.M., Daud A., Malik M.K., Bukhari A., Alsahfi T., Alshemaimri B. 2025. BERT applications in natural language processing: a review. *Artificial Intelligence Review* 58(6): 1–49.
32. Rigatti S.J. 2017. Random forest. *Journal of Insurance Medicine* 47(1): 31–39.
33. Breiman L. 2001. Random forests. *Machine Learning* 45: 5–32.
34. Sherstinsky A. 2020. Fundamentals of recurrent neural network (RNN) and long short-term memory (LSTM) network. *Physica D: Nonlinear Phenomena* 404: 132306.
35. Staudemeyer R.C., Morris E.R. 2019. Understanding LSTM – a tutorial into long short-term memory recurrent neural networks. arXiv:1909.09586.
36. Yu Y., Si X., Hu C., Zhang J. 2019. A review of recurrent neural networks: LSTM cells and network architectures. *Neural Computation* 31(7): 1235–1270.
37. Koroteev M.V. 2021. BERT: a review of applications in natural language processing and understanding. arXiv:2103.11943.
38. Jawahar G., Sagot B., Seddah D. 2019. What does BERT learn about the structure of language? W: ACL 2019 – 57th Annual Meeting of the Association for Computational Linguistics.
39. Rogers A., Kovaleva O., Rumshisky A. 2021. A primer in BERTology: What we know about how BERT works. *Transactions of the Association for Computational Linguistics* 8: 842–866.
40. Susmaga R. 2004. Confusion matrix visualization. W: *Intelligent Information Processing and Web Mining*, Zakopane: 107–116.
41. Lever J. 2016. Classification evaluation: understanding what a classification metric expresses and hides. *Nature Methods* 13(8): 603–605.

42. Hossin M., Sulaiman M.N. 2015. A review on evaluation metrics for data classification evaluations. *International Journal of Data Mining & Knowledge Management Process* 5(2): 1–10.
43. Metz C.E. 1978. Basic principles of ROC analysis. *Seminars in Nuclear Medicine* 8(4): 283–298.
44. Olson D.L. 2004. Data set balancing. W: *Chinese Academy of Sciences Symposium on Data Mining and Knowledge Management*, Berlin: 71–80.
45. Westgard J.O., Lott J.A. 1981. Precision and accuracy: concepts and assessment by method evaluation testing. *CRC Critical Reviews in Clinical Laboratory Sciences* 13(4): 283–330.
46. Zhou Y., Srikumar V. 2021. A closer look at how fine-tuning changes BERT. *arXiv:2106.14282*.
47. Merchant A., Rahimtoroghi E., Pavlick E., Tenney I. 2020. What happens to BERT embeddings during fine-tuning? *arXiv:2004.14448*.
48. Sun C., Qiu X., Xu Y., Huang X. 2019. How to fine-tune BERT for text classification? W: *China National Conference on Chinese Computational Linguistics*, Cham: 194–206.

Internet

1. <https://www.brightlocal.com/research/local-consumer-review-survey/> (dostęp 5 maja 2025)
2. <https://uokik.gov.pl/recenzje-szyte-na-miare-zarzuty-prezesa-uokik-wobec-best-review> (dostęp 5 maja 2025)

8. Spis rysunków

Rysunek 1. Jak często użytkownicy czytają opinie w Internecie? (zawsze, regularnie, czasem, nigdy).....	10
Rysunek 2. Rozkład zmiennej objaśnianej.....	17
Rysunek 3. Podział opinii według kategorii produktowych	17
Rysunek 4. Rozkład długości opinii pod względem ilości wyrazów	17
Rysunek 5 Graficzne przedstawienie funkcji logistycznej	21
Rysunek 6 Krzywa ROC oraz pole pod krzywą,	28
Rysunek 7 Macierz pomyłek dla zbioru treningowego, regresja logistyczna Źródło: opracowanie własne	31
Rysunek 8 Macierz pomyłek dla danych testowych (Regresja logistyczna) Źródło: opracowanie własne	32
Rysunek 9 Krzywa ROC oraz metryki AUC dla zbiorów treningowego i testowego Źródło: opracowanie własne	33
Rysunek 10 Macierz pomyłek dla danych treningowych, Las Losowy	35
Rysunek 11 Macierz pomyłek dla danych testowych, Las Losowy	36
Rysunek 12 Krzywa ROC oraz metryki AUC dla zbiorów treningowego i testowego, Las Losowy	37
Rysunek 13 Przebieg uczenia sieci LSTM, 1 - zmiana dokładności na zbiorach testowym i walidacyjnym, 2 - zmiana straty na zbiorach testowym i walidacyjnym	40
Rysunek 14 Macierz pomyłek dla zbioru treningowego, LSTM	41
Rysunek 15 Macierz pomyłek dla zbioru testowego, LSTM.....	42
Rysunek 16 Krzywe ROC oraz metryki AUC dla zbiorów treningowego i testowego, LSTM	43
Rysunek 17 Przebieg uczenia modelu BERT, straty na zbiorach treningowym i testowym	45
Rysunek 18 Zmiana dokładności oraz AUC na zbiorze testowym podczas uczenia BERT.....	45
Rysunek 19 Macierz pomyłek dla zbioru treningowego (BERT).....	46
Rysunek 20 Macierz pomyłek dla zbioru testowego (BERT).....	47
Rysunek 21 Krzywe ROC dla zbiorów testowego i treningowego (BERT).....	48

9. Spis tabel

Tabela 1 Struktura macierzy pomyłek dla klasyfikacji binarnej	26
Tabela 2 Przetestowane kombinacje hiperparametrów (Regresja logistyczna).....	30
Tabela 3 Przetestowane kombinacje hiperparametrów (Las Losowy)	34
Tabela 4 Przetestowane hiperparametry, LSTM	38
Tabela 5 Przetestowane parametry do uczenia BERT	44
Tabela 6 Przebieg trenowania modelu BERT.....	44
Tabela 7 Podsumowanie wyników klasyfikacji dla opracowanych modeli na zbiorze testowym.	49

Wyrażam zgodę na udostępnienie mojej pracy w czytelniach Biblioteki SGGW
w tym w Archiwum Prac Dyplomowych SGGW

.....
(czytelny podpis autora pracy)